TD2: Satistiques non paramétriques - estimation d'une densité

Exercice 1

Soit $(\phi_k)_{k\geqslant 0}$ une famille de polynômes tels que :

- pour tout $k \geq 0$, ϕ_k est de degré k;
- pour tout $k, k' \ge 0$, $\int_{-1}^{1} \phi_k(u)\phi_{k'}(u)du = \delta_{k,k'}$.
 - 1. Écrire ϕ_0 , ϕ_1 et ϕ_2 .
 - 2. Montrer que pour tout $\ell \geqslant 0$, $\sum_{m=0}^{\ell} \phi_m(0)\phi_m(u)\mathbb{1}_{[-1,1]}(u)$ est un noyau d'ordre ℓ .

Exercice 2

Soient (X_1, X_n) des variables aléatoires i.i.d. de loi de densité p_* par rapport à la mesure de Lebesgue. On rappelle que, pour tout h > 0, l'estimateur J_n^h de l'erreur moyenne quadratique intégrée est sans biais :

$$J_n^h = \int_{\mathbb{R}} p_{\star}^2(x) dx + \int_{\mathbb{R}} (\widehat{p}_n^h)^2(x) dx - \frac{2}{n(n-1)h} \sum_{i=1}^n \sum_{j \neq i}^n K\left(\frac{X_i - X_j}{h}\right),$$

οù

$$\widehat{p}_n^h: x \mapsto \frac{1}{nh} \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right).$$

Calculer J_n^h dans le cas du noyau gaussien $K: u \mapsto (2\pi)^{-1/2} e^{-u^2/2}$.

Exercice 3

Pour tout $m \ge 1$ on considère (C_1, \ldots, C_m) la partition uniforme de [0,1) définie, pour tout $1 \le i \le m$, par $C_i = [(i-1/m), i/m)$. Soient (X_1, \ldots, X_n) des variables aléatoires i.i.d. de loi de densité p_* par rapport à la mesure de Lebesgue sur [0,1). On considère l'estimateur par histogramme de la densité p_* :

$$\widehat{p}_n^h : x \mapsto \frac{1}{nh} \sum_{i=1}^n \sum_{j=1}^m \mathbb{1}_{C_j}(X_i) \mathbb{1}_{C_j}(x),$$

où h=1/m.

- 1. Évaluer l'erreur quadratique moyenne associée à cet estimateur.
- 2. Évaluer l'erreur quadratique moyenne intégrée associée à cet estimateur.
- 3. (Bonus) Dans le cas où p_{\star} est \mathcal{C}^2 sur \mathbb{R} , donner un développement asymptotique de l'erreur quadratique moyenne intégrée.

Exercice 4

Soient (X_1, X_n) des variables aléatoires i.i.d. de loi de densité p_* par rapport à la mesure de Lebesgue sur \mathbb{R} . La densité p_* est estimée par l'estimateur par fenêtre glissante:

$$\widehat{p}_n^{h_n}: x \mapsto \frac{1}{2nh_n} \sum_{i=1}^n \mathbb{1}_{(x-h_n, x+h_n)}(X_i).$$

1. Écrire la décomposition biais-variance pour cet estimateur.

- 2. Montrer que lorsque $h_n \to 0$ et $nh_n \to +\infty$ alors, pour presque tout x, $\widehat{p}_n^{h_n}(x)$ converge dans L^2 (et donc en probabilité) vers $p_*(x)$.
- 3. Considérons une suite $(S_n)_{n\geqslant 1}$ de variables aléatoires indépendantes de lois binomiales de paramètres n et p_n avec $np_n\to +\infty$ et limsup $p_n<1$. Pour tout $t\in\mathbb{R}$, en remarquant que

$$p_n \frac{t^2}{np_n(1-p_n)} = O\left(\frac{1}{n}\right) \quad \text{et} \quad p_n^2 \frac{t^2}{np_n(1-p_n)} = O\left(\frac{1}{n}\right) ,$$

effectuer un développement limité de $\mathbb{E}[\mathrm{e}^{itZ_n}]$ où

$$Z_n = \frac{S_n - np_n}{\sqrt{np_n(1 - p_n)}}.$$

4. Montrer que:

$$Z_n \Rightarrow \mathcal{N}(0,1)$$
.

5. Soit x un réel tel que f(x) > 0 et tel que f est dérivable sur dans un voisinage V(x), de dérivée bornée sur ce voisinage. Montrer que si $nh_n \to +\infty$ et $nh_n^3 \to 0$ alors :

$$\sqrt{\frac{2nh_n}{\widehat{p}_n^{h_n}(x)}} \left(\widehat{p}_n^{h_n}(x) - p_{\star}(x) \right) \Rightarrow \mathcal{N}(0,1) .$$